# 2부 — 분류와 평가

입시 합격 예측 · 데이터 추가 후 재학습 · 정확도 · 평가의 함정

앱 페이즈 6~9 · 대상: 고등학생 · 활동 시간 약 75분

**학습 목표** ① 회귀에서 분류로 넘어갈 때 모델이 어떻게 달라지는지 설명한다. ② 학습 데이터의 양이 일반화에 미치는 영향을 관찰한다. ③ 정확도·정밀도·재현율을 구분해 사용하고, 어떤 상황에서 어떤 지표가 중요한지 판단한다.

학년 반 번호 _____ 이름 _____

## STEP 1. 입시 합격 예측 — 가중치 추적

**이 절의 목표**

대학이 비공개한 합격 기준을 **합격자/불합격자 명단의 점수**로부터 거꾸로 추적할 수 있는지 직접 손계산으로 확인한다.

**분류 = 0/1 결정** — 1부에서는 연속 값을 맞히는 **회귀**였다. 2부는 합격(1)/불합격(0)을 가르는 **분류**.

- 점수 = $w_1$·국 + $w_2$·수 + $w_3$·영 + $w_4$·탐 → 점수 > 컷오프면 합격, 점수 ≤ 컷오프면 불합격(앱과 동일한 규칙).
- 가중치(w)·컷오프는 비공개. 우리는 결과(합·불)만 보고 **가중치 비율을 거꾸로 추정**한다.

**활동지 = 손계산용 축소판** — 앱 페이즈 6은 학생 **10명**으로, 페이즈 7은 데이터를 **40명**까지 늘려가며 학습합니다. 활동지에서는 손으로 직접 채워넣을 수 있도록 **6명 → 30명**으로 줄였어요. 비율과 패턴이 잘 보이도록 일부러 깔끔한 숫자를 골랐습니다(앱은 더 풍부한 데이터로 같은 절차를 진행합니다).

### 1-1 학습 데이터 — 정시 시나리오 6명

○○대학교 정시 합격자 3명·불합격자 3명의 점수 (각 1~10점). 사람이 보면 어떤 과목이 큰 영향일 것 같은가?

| 학생 | 국어 | 수학 | 영어 | 탐구 | 실제 결과 |
|---|---|---|---|---|---|
| 김민서 | 8 | 9 | 7 | 7 | 합격 |
| 이지우 | 6 | 9 | 6 | 8 | 합격 |
| 박서연 | 7 | 8 | 6 | 7 | 합격 |
| 최도윤 | 9 | 5 | 8 | 6 | 불합격 |
| 정하준 | 7 | 5 | 8 | 7 | 불합격 |
| 강시우 | 6 | 6 | 9 | 5 | 불합격 |

합격 3명과 불합격 3명을 가르는 가장 큰 차이는 어느 과목인 것 같나요? 한 줄로:

## 1-2 가중치 후보 W1 (균등) — 직접 계산

먼저 균등 가중치로 시도합니다. $w_1 = w_2 = w_3 = w_4 = 0.25$, 컷오프 = 7.0.

점수 = 0.25·국 + 0.25·수 + 0.25·영 + 0.25·탐 = (네 점수의 평균). 6명의 점수와 분류 결과를 채우세요.

| 학생 | 점수 (네 과목 평균) | 예측 (>7 합격) | 실제 | 맞음/틀림 |
|---|---|---|---|---|
| 김민서 | | | 합격 | |
| 이지우 | | | 합격 | |
| 박서연 | | | 합격 | |
| 최도윤 | | | 불합격 | |
| 정하준 | | | 불합격 | |
| 강시우 | | | 불합격 | |

정확도 = 맞음 개수 / 6 = _____ / 6 = _____%

## 1-3 가중치 후보 W2·W3 — 결과 비교

두 가지 다른 가중치로 같은 6명을 분류한 결과를 미리 제공합니다.

| 가중치 | $w_1$ 국 | $w_2$ 수 | $w_3$ 영 | $w_4$ 탐 | 정확도 (6명 학습) |
|---|---|---|---|---|---|
| W1 균등 | 0.25 | 0.25 | 0.25 | 0.25 | (1-2에서) |
| W2 수학 강조 | 0.10 | 0.50 | 0.20 | 0.20 | 100% |
| W3 영어 강조 | 0.20 | 0.20 | 0.40 | 0.20 | 33% |

세 가중치 중 어느 게 가장 잘 분류했나요? _____

"비밀 공식"을 어떻게 추적했나요? 한 줄로 적어보세요.

## 1-4 학습 vs 시험 — 새 데이터 4명

학습에 쓰지 않은 새 학생 4명 데이터에 W2(수학 강조)를 적용한 결과:

| 학생 | 국 | 수 | 영 | 탐 | 점수 (W2) | 예측 | 실제 | 맞음? |
|---|---|---|---|---|---|---|---|---|
| 윤서아 | 7 | 8 | 7 | 8 | 7.4 | 합격 | 합격 | ✓ |
| 장이안 | 9 | 6 | 7 | 6 | 6.5 | 불합격 | 합격 | ✗ |
| 임채원 | 5 | 5 | 6 | 6 | 5.4 | 불합격 | 불합격 | ✓ |
| 한수아 | 6 | 7 | 7 | 5 | 6.5 | 불합격 | 불합격 | ✓ |

학습 정확도(6명) = 100 %, 시험 정확도(4명) = _____ / 4 = _____%

두 정확도가 차이 나는 이유는 무엇일까요? 한 줄로:

## STEP 2. 데이터 추가 후 재학습

**이 절의 목표**

학습 데이터를 6명 → 30명으로 늘리면 **가중치·정확도가 어떻게 달라지는지** 결과를 비교하며 일반화의 의미를 짚는다.

### 2-1 6명 → 30명, 결과 비교

아래는 같은 시나리오에서 학습 데이터를 늘려 학습한 결과입니다.

| | 6명일 때 | 30명일 때 |
|---|---|---|
| **최적 가중치 (국·수·영·탐)** | 0.10·**0.50**·0.20·0.20 | 0.15·**0.45**·0.20·0.20 |
| **학습 정확도** | 100% | 93% |
| **시험 정확도(새 학생 20명)** | 75% | 90% |

표를 보고 빈칸을 채우세요.

학습 정확도는 (올라갔다 / 내려갔다). ☞ _____
시험 정확도는 (올라갔다 / 내려갔다). ☞ _____
두 정확도의 격차가 (커졌다 / 줄었다). ☞ _____

### 2-2 가상 인물 합·불 통지

30명 학습 후 W2(수학 강조)로 가상 학생 3명을 분류한 결과를 미리 제공합니다.

| 가상 학생 | 국 | 수 | 영 | 탐 | 점수 | 모델 판정 |
|---|---|---|---|---|---|---|
| P1 (전체 우수) | 9 | 9 | 9 | 9 | 9.0 | 합격 |
| P2 (수학 약점) | 9 | 5 | 9 | 9 | 7.0 | 경계 (합격) |
| P3 (수학 강점만) | 5 | 9 | 5 | 5 | 7.0 | 경계 (합격) |

P2와 P3의 점수가 같은데, 사람이 보기엔 어느 쪽이 더 합격에 가까울까요? 그 직관과 모델의 판정을 비교하면?

### 2-3 일반화 (generalization)

> 학습한 데이터에서 잘 맞히는 것보다, **처음 보는 데이터에서 잘 맞히는 능력**이 진짜 실력. 이걸 **일반화**라 한다.

2-1 표에서 학습 정확도는 떨어졌는데 시험 정확도는 올랐어요. 이게 왜 일반화 관점에서 좋은 신호인가요?

## STEP 3. 정확도와 혼동행렬

> **이 절의 목표**
> 분류 결과를 4가지로 나누는 **혼동행렬**을 직접 채우고, 정확도 한 숫자만 보면 무엇을 놓치는지 사고 실험으로 확인한다.

> **혼동행렬 (confusion matrix)** 예측과 실제를 2×2로 나눈 표.
> ▸ TP(진짜 양성) · FP(거짓 양성, 오인) · FN(거짓 음성, 놓침) · TN(진짜 음성)

### 3-1 시험 데이터 20명 결과 — 혼동행렬 채우기

시험 학생 20명에게 모델을 적용한 결과를 분류해 둔 표입니다. 빈칸의 4가지 합계를 채우세요.

| 실제 / 예측 | 예측 합격 | 예측 불합격 | 실제 합계 |
|---|---|---|---|
| **실제 합격** | 진짜 합격을 합격으로 8명 | 합격을 놓침 2명 | |
| **실제 불합격** | 불합격을 합격으로 오인 1명 | 진짜 불합격을 불합격으로 9명 | |

TP = _____ · FP = _____ · FN = _____ · TN = _____

### 3-2 정확도 계산

```
정확도 = (TP + TN) / 전체 = ( _____ + _____ ) / 20 = _____%
```

**3-3** **정확도의 함정 — 사고 실험**

합격자 1명 · 불합격자 99명인 시험에서 모델이 "**전원 불합격**"이라고만 외친다면?

```
정확도 = (TP + TN) / 100 = ( _____ + _____ ) / 100 = _____%
```

이 모델이 정확도가 매우 높음에도 쓸모없는 이유를 한 줄로:

## STEP 4. 평가의 함정 — 정밀도와 재현율

**이 절의 목표**

코로나·암 검진처럼 **"놓치면 큰일 / 오인하면 큰일"의 비용 비대칭**이 있는 분야에서 정밀도·재현율을 직접 계산해 어느 쪽을 우선해야 하는지 판단한다.

**한 줄 약속 — "양성 = 이번에 찾고 싶은 것"**

"양성(positive)"은 좋은 일이 아니라 **이번에 우리가 찾아내고 싶은 사건**이에요. 코로나에서는 감염자, 암 검진에서는 암 환자, 스팸 필터에서는 광고 메시지가 양성. 누가 양성인지 정해지면 TP·FP·FN·TN의 의미가 자동으로 결정됩니다.

**정밀도 vs 재현율**

▸ **정밀도(Precision)** = TP / (TP + FP) — 양성이라 외친 것 중 **진짜 양성** 비율. "헛발질이 적은가?"
▸ **재현율(Recall)** = TP / (TP + FN) — 진짜 양성 중 **잡아낸** 비율. "놓침이 적은가?"
→ 둘은 보통 **한쪽을 올리면 다른 쪽이 내려간다**(트레이드오프).

🎭 **마피아 게임 비유 — 두 친구의 성격 차이**

같은 마피아 게임을 한다고 합시다. 양성 = 마피아, 음성 = 시민. 모델은 "이 사람이 마피아야!"라고 지목하는 플레이어예요. 두 친구의 성격이 정밀도·재현율과 그대로 대응합니다.

- 🧐 **정밀도가 높은 친구 — "신중파"** 확실할 때만 손가락질해요.
  - 👍 함부로 시민을 처형하지 않아 신뢰가 쌓임. 한 번 지목하면 다른 친구들도 따라줌.
  - 👎 의심돼도 증거 부족이라며 가만히 있다가 *마피아를 살려두기* 쉬움.
- 🗣️ **재현율이 높은 친구 — "적극파"** 조금만 수상해도 외쳐요.
  - 👍 마피아를 거의 놓치지 않아요. 결정적 순간에 망설이지 않음.
  - 👎 시민을 자꾸 잘못 처형해 마을이 텅 비고, 자꾸 틀리면 진짜 마피아를 지목해도 *아무도 안 믿어줌*(양치기 소년).

🤔 **어느 쪽이 더 중요할까?** 정답은 없어요. 마피아가 1명만 남았을 땐 정밀도가, 절반일 땐 재현율이 더 절실해요. 의료·면접·메시지 필터에서도 같은 질문 — **어느 비용이 더 큰가?** 그게 임계값을 결정해요.

**임계값(threshold)이란?**

모델은 각 사람에게 **0~1 사이 양성 확률**을 출력해요(1에 가까울수록 양성 확실). 그런데 확률만으로는 양/음을 결정 못 하니, **어디서 자를지**를 정해야 합니다 — 이 자르는 위치가 임계값. 예: 임계값 0.5 → 0.5 이상이면 양성. 임계값을 **낮추면** 양성이라 부르는 사람이 늘어나 재현율↑·정밀도↓, **높이면** 그 반대.

## 4-1 코로나 진단 시나리오 — 임계값 변화

인구 1000명 검사. 실제 양성 20명, 음성 980명. 임계값을 바꿔가며 분류한 결과:

| 임계값 | TP | FP | FN | TN | 정확도 | 정밀도 | 재현율 |
|---|---|---|---|---|---|---|---|
| 0.3 (낮음) | 19 | 120 | 1 | 860 | | | |
| 0.5 (중간) | 16 | 30 | 4 | 950 | | | |
| 0.7 (높음) | 10 | 5 | 10 | 975 | | | |

소수점 둘째 자리까지 계산. (정확도 = (TP+TN)/1000, 정밀도 = TP/(TP+FP), 재현율 = TP/(TP+FN))

## 4-2 임계값을 어떻게 정해야 할까

**FN의 비용** (놓치면) — 진짜 환자를 놓치면 본인 악화 + 주변 전염.
**FP의 비용** (오인하면) — 음성인데 양성 판정받아 격리·재검사 부담.

코로나는 어느 쪽이 더 큰 문제일까요? 그 이유로 임계값을 **높이면 / 낮추면** 좋은가요? (동그라미)

## 4-3 암 조기검진 시나리오 — 직접 계산

인구 1000명 정기검진. 실제 양성 5명, 음성 995명. 임계값별 결과:

| 임계값 | TP | FP | FN | TN | 정밀도 | 재현율 |
|---|---|---|---|---|---|---|
| 0.3 (낮음) | 5 | 80 | 0 | 915 | | |
| 0.5 (중간) | 4 | 20 | 1 | 975 | | |
| 0.7 (높음) | 2 | 3 | 3 | 992 | | |

암 검진은 어느 쪽을 더 중요하게 봐야 할까요? 코로나와 비교해 같은가, 다른가?

## 4-4 1000명 중 5명 양성, 정확도 99.5%? — 함정 풀기

암 검진(실제 양성 5명, 음성 995명)에서 모델이 모두 "음성"이라고만 답해도 정확도 99.5%가 나옵니다.

```
이 모델의 재현율 = TP / (TP + FN) = _____ / ( _____ + _____ ) = _____%
이 모델의 정밀도 = TP / (TP + FP) = _____   (계산 불가? 그 이유는?)
```

### 4-5 시나리오 미니퀴즈 — 어느 쪽에 무게를?

상황이 바뀌면 같은 모델이라도 임계값을 다르게 잘라야 해요. 두 시나리오를 골라 직접 판단해 보세요.

💼 **회사 면접** 진짜 천재(양성)는 한 명도 놓치고 싶지 않은데, 회사에 해를 끼칠 빌런은 절대 들이면 안 돼요. 어디에 무게를 둘까?

| 선택 | 효과 | 예상 결과 (한 줄) |
|---|---|---|
| 재현율 ↑ (천재 놓치지 않기) | 임계값을 (낮춤 / 높임) ☞ _____ | |
| 정밀도 ↑ (빌런 거르기) | 임계값을 (낮춤 / 높임) ☞ _____ | |

현실 해법은? — 1차 서류, 2차 면접의 다단계 채용이 등장하는 이유를 한 줄로 적으세요.

💬 **메시지 스팸 필터** 단체 채팅방에 광고가 섞여 와요(양성=광고). 친구의 중요한 안내(음성)는 절대 가리면 안 되고, 광고는 짜증나요. 어디에 무게를 둘까?

| 선택 | FN의 비용 (놓침) | FP의 비용 (오인) |
|---|---|---|
| 재현율 ↑ (광고 다 잡기) | 광고 새는 일 적음 | 친구 메시지가 가끔 광고함으로 |
| 정밀도 ↑ (확실한 광고만) | 일부 광고가 새어 들어옴 | 친구 메시지는 안전 |

대부분의 메시지 앱은 어느 쪽을 우선할까요? 그 이유를 한 줄로:

## STEP 5. 2부 마무리

### 정리 지표 선택 가이드

| 상황 | 가장 중요한 지표 | 그 이유 |
| --- | --- | --- |
| 스팸 메일 분류 (정상 메일을 스팸함에 넣으면 큰 손해) | | |
| 암 조기검진 (놓치면 생존율 급락) | | |
| 입시 합격 예측 (반반 비슷한 비율) | | |

서술 **친구에게 설명하기**

"왜 정확도 하나만 보면 안 되는가?"를 정밀도·재현율 개념을 사용해 5~7문장으로 설명하세요.