2부 — 분류와 평가

앱 페이즈 6~9 · 학생용과 동일 구조 + 정답·해설·관찰 루브릭

> **핵심 메시지** "정확도 한 숫자에 속지 말 것." 합·불, 양성·음성처럼 **비대칭 비용**을 가진 문제에서는 정밀도·재현율을 함께 봐야 한다는 감각을 심는 것이 2부 전체의 목표.

STEP 1. 입시 합격 예측 (Phase 6)

앱 운영 학생들이 시나리오를 자유 선택. 한 반에서 A·B가 섞여도 좋다. **둘 다 풀게 하면 시간 부족**이므로 1개 선택 후 STEP 2~4까지 같은 시나리오 유지.

1–1 변수 — 정답

시나리오 A 정시 x_1 **국어** · x_2 **수학** · x_3 **영어** · x_4 **탐구** (모두 1~10점)

시나리오 B 학종 x_1 **학업역량** · x_2 **진로역량** · x_3 **공동체역량** · x_4 **면접** (모두 1~10점)

1–2 가중치 조정 — 운영 가이드

수업 팁 처음 슬라이더 위치는 모두 0.25(균등). 학생들이 무작정 올리지 않도록 **"합격자에서 가장 높은 변수가 무엇인지"**부터 명단을 들여다보고 시작하게 안내. 한 슬라이더만 0.5로 올려 변화 보고 → 다음 슬라이더 → 식으로 한 번에 한 변수만 움직이는 절차를 시범.

관찰 포인트 학생들이 가중치를 키우다가 컷오프를 함께 올리지 않으면 **전원 합격**으로 정확도가 50% 부근에 멈춘다. "합격 컷"의 역할을 짚어줄 시점.

1–3 학습 vs 시험 정확도 — 모범 답안

예시 결과 10명 학습 후 학습 정확도 ≈ 100%인데 시험 정확도는 70~80% 수준에 머무는 경우가 많음. 시나리오에 따라 차이.

차이 원인 10명만 보고 정한 가중치는 그 10명의 우연한 패턴까지 외운 것이라, 새 20명에게는 잘 맞지 않는다. → **과적합(overfitting)**의 직관적 설명. (용어는 STEP 2에서 함께 도입.)

자주 틀림 "학습 정확도가 높을수록 좋은 모델"이라는 오해. 실제 평가는 시험 정확도로만 한다는 점을 강조.

1–4 **비밀 공식 추적 — 모범 답안**

예시 합·불 결과는 가중치의 **흔적**이기 때문. 결과가 충분히 모이면 그 결과를 만들어낸 비율을 거꾸로 추정할 수 있다.

STEP 2. 데이터 추가 후 재학습 (Phase 7)

2–1·2–2 **예시 결과**

전형 패턴 10명 → 40명으로 늘리면 **학습 정확도는 약간 떨어지고 시험 정확도는 올라간다**. 즉 두 정확도가 가까워진다.

가중치 10명 시점의 "외운 가중치"가 무너지고, 4영역 모두에 분산된 더 일반적인 비율로 이동.

수업 팁 가상 인물 P1·P2·P3에서 **한 영역만 약점인 학생**이 합/불 어느 쪽으로 분류되는지를 비교하면, 그 시나리오에서 가장 큰 가중치가 어디 있는지 학생 스스로 발견할 수 있음.

2–3 **일반화 — 모범 답안**

예시 데이터가 많아지면 우연한 잡음이 평균에 묻혀 사라지고, 데이터를 만든 진짜 규칙이 더 잘 드러난다. 그래서 새 데이터에도 통하는 모델이 된다.

> **전이 메시지** "데이터가 곧 권력이다." 이 직관이 거대 모델 시대의 핵심.

STEP 3. 정확도와 혼동행렬 (Phase 8)

3–1·3–2 **혼동행렬 — 운영**

수업 팁 학생마다 페이즈 7 가중치가 다르므로 결과 값이 모두 다르다. 정답 숫자를 외우는 게 아니라 "**네 칸이 합쳐져 20이 되는지**"만 점검할 것. 정확도 = (TP+TN)/20.

참고 범위 대부분 시험 정확도 70~95% 사이에 분포. TP+TN ≥ 14 면 우수 수준.

3–3 **정확도 함정 — 정답**

정답 전원 불합격이라 외치면 정확도 = 99/100 = **99%**.

비판 예시 합격자 1명을 100% 놓치는데도 정확도는 99%. 정확도 한 숫자만으로는 "쓸모"를 평가할 수 없다.

자주 틀림 합격자 수를 1로 잡았는데 99%로 답하지 않고 100%로 답하는 경우. 분모 = 100명 임을 다시 확인.

STEP 4. 평가의 함정 — 정밀도·재현율 (Phase 9)

4-1 코로나 — 임계값별 경향

정성적 경향 임계값을 **낮출수록** TP·FP↑ / FN·TN↓ → 재현율↑, 정밀도↓.
높일수록 반대 방향. 정확도는 임계값 0.4~0.6 부근에서 최대인 경우가 많음.

임계값	재현율 경향	정밀도 경향
0.3	높음 (놓침 적음)	낮음 (FP 많음)
0.5	중간	중간
0.7	낮음 (놓침 많음)	높음

4-2 코로나 임계값 결정 — 모범 답안

정답 FN(놓침) 비용 ≫ FP 비용 → **재현율을 우선** → 임계값을 **낮춘다**. 약간의 오인(격리)은 감수하고 환자를 놓치지 않는 쪽.

4-3 암 검진 — 모범 답안

정답 코로나와 같은 방향: 놓침이 더 큰 비용 → **재현율 우선**. 다만 암은 추가 검사 비용·환자 불안이 코로나의 격리보다 크므로 임계값을 무한정 낮추진 못함. **1차 검진은 재현율 우선, 2차 정밀검사로 정밀도 회복**이 실제 의료의 패턴.

전이 "단계적 검진 = 임계값을 다르게 둔 모델 두 개의 직렬 연결"이라는 메타 메시지를 함께 짚어주면 좋음.

4-4 모두 음성 모델의 정밀도·재현율 — 정답

계산 재현율 = TP / (TP + FN) = **0** / (**0** + **5**) = **0%**
정밀도 = TP / (TP + FP) = 0 / 0 → **정의 불가** (양성이라 외친 적이 없으므로 분모 = 0).

의미 이 모델은 양성 환자를 단 한 명도 못 잡았고(재현율 0), "양성"이라는 판정 자체를 한 적이 없어 정밀도는 정의되지 않는다. 정확도 99.5%라는 숫자가 얼마나 거짓 위안인지 한 번에 드러난다.

자주 틀림 정밀도를 0%로 답하는 경우. 0/0은 0이 아니라 "정의 불가"임을 짚을 것.

STEP 5. 마무리 — 지표 선택 가이드

정리 **정답 매트릭스**

상황	가장 중요한 지표	이유
스팸 메일 분류	**정밀도**	정상 메일을 스팸함으로 보내면(FP) 사용자가 중요한 메일을 놓침. FP 비용이 크다.
암 조기검진	**재현율**	진짜 환자를 놓치면(FN) 생존율 급락. FN 비용이 가장 크다.
입시 합격 예측	**정확도(또는 균형 F1)**	합·불 비율이 비슷하고 두 오류의 비용이 비슷하면 정확도가 무난.

관찰·수행 평가 루브릭

수준	분류 모델 조작	혼동행렬·지표	지표 선택 판단
A 도달	한 번에 한 변수씩 조정해 시험 정확도를 80% 이상으로 끌어올림. 학습/시험 정확도 차이를 일반화 개념으로 설명.	정확도·정밀도·재현율을 모두 정의에 따라 정확히 계산. 임계값 변화의 트레이드오프를 자기 말로 설명.	3개 시나리오 모두에서 비용 구조에 맞는 지표를 정확히 골라 이유 설명.
B 진행	가중치 조정으로 70% 부근까지 도달. 두 정확도 차이의 의미는 모호.	정확도는 계산하지만 정밀도·재현율 분모를 헷갈림.	스팸·암 중 한 쪽은 맞히지만 이유가 단편적.
C 보충	슬라이더를 무작위로 움직여 정확도가 50%대.	TP/FP/FN/TN의 의미를 구분하지 못함.	"정확도 높으면 좋은 모델"이라는 인식에 머무름.

전이 포인트 2부에서 다룬 모든 분류는 **점수 계산 + 임계값 비교**의 단일 뉴런이었다. 3부에서 같은 도구로 픽셀 단위 도트 그림을 분류하면서 "특징이 많아지면 어떻게 되는가"를 묻게 된다.