3·4부 — 직접 만들기와 깊은 학습

앱 페이즈 10~12 · 학생용과 동일 구조 + 정답·해설

> **핵심 메시지** "복잡한 문제는 더 큰 신경망을 요구한다, 그러나 크기만 키우면 과적합이 늘어난다." 3·4부에서는 모델 크기·데이터 양·증강 세 축으로 일반화 감각을 길러내는 게 목표.

STEP 1. 도트 그림 학습 (Phase 10)

앱 운영 한 라벨당 **최소 5장**을 권장. 시간이 부족하면 앱의 "프리셋 불러오기"로 기본 데이터셋을 채운 뒤 학생이 1~2장만 추가하게 한다.

1–2 학습 관찰 — 전형 패턴

예시 라벨당 3장: 학습 정확도 100% / 새 그림 적중 50~70%
라벨당 5장: 학습 정확도 100% / 새 그림 적중 70~85%
라벨당 10장: 학습 정확도 95% 부근(소폭 하락) / 새 그림 적중 85~95%

수업 팁 3장에서 학습 정확도가 100%인데 테스트가 50%라면 **외운 모델**임을 강조 — 2부에서 다룬 일반화 개념의 자연스러운 복습.

1–3 가중치 시각화 — 모범 답안

관찰 예시 가중치 그림은 **두 라벨의 평균 차이**처럼 보인다. 라벨 A가 자주 켜진 자리는 양수(밝음), B가 자주 켜진 자리는 음수(어두움). 두 그림이 겹치는 부분은 0(회색).

한 줄 정의 "단일 뉴런이 두 그림을 구분한다 = **두 라벨의 픽셀 차이를 평균낸 패턴과 입력의 내적을 보고, 양수면 A·음수면 B로 결정하는 일**." (학생 답이 "비슷한 무늬가 그림을 구분한다"라는 직관 수준이어도 인정.)

수업 팁 학생들이 "고양이 vs 강아지"처럼 너무 자유로운 라벨을 고르면 학습이 안 된다. 처음에는 **대조가 강한 라벨**(원 vs X, 가로줄 vs 세로줄)을 권하고, 그다음에 자유 주제로.

STEP 2. 신경망 설계 (Phase 11)

2–1 단계 A·B·C — 전형 결과

앱 운영 각 단계 학습은 수십 초 ~ 1분. 한 단계가 끝나면 같은 신경망 구조로 다음 단계 진행. 시간이 부족하면 단계 A·C 두 개만 비교해도 메시지는 전달됨.

단계	클래스	은닉 = 8 일 때 파라미터 수(개략)	전형 시험 정확도
A	2	**≈ 6,300**	**99% 부근**
B	3	**≈ 6,300**	**95~98%**
C	10	**≈ 6,400**	**75~85%**

파라미터 계산법 층 사이 파라미터 = (in+1) × out. 입력 784, 은닉 8, 출력 c일 때 = 785·8 + 9·c. 단계 C(c=10): 6280 + 90 = **6370**. (학생이 정확한 수치 대신 "비슷하다"고 답해도 OK.)

2-2 은닉 키우기 (단계 C) — 전형 결과

은닉 크기	4	8	16	32
파라미터 수	**≈ 3.2k**	**≈ 6.4k**	**≈ 12.7k**	**≈ 25.4k**
시험 정확도	**≈ 70%**	**≈ 82%**	**≈ 88%**	**≈ 91%**

관찰 모범 답안 은닉을 키우면 정확도가 오르지만 **증가폭이 점점 작아진다**(수확체감). 매우 작은 데이터로 너무 키우면 학습 정확도와 시험 정확도가 벌어지는 **과적합**이 보이기 시작한다.

2-3 1·7 혼동 — 모범 답안

예시 1과 7은 모두 **세로 직선이 핵심 특징**이다. 7은 위쪽에 짧은 가로획이 추가될 뿐이라, 가로획이 흐릿하거나 작은 글씨에서 신경망이 두 클래스의 신호를 분리하기 어렵다.

STEP 3. MNIST 도전 (Phase 12)

3-1 구조·설정 변화 — 전형 결과

설정	은닉	학습 정확도	시험 정확도
기본	[4]	**≈ 70%**	**≈ 65%**
은닉 키움	[32]	**≈ 92%**	**≈ 88%**
2층	[32, 16]	**≈ 95%**	**≈ 90%**
에폭 늘림	[32, 16] · 10ep	**≈ 99%**	**≈ 92%**

관찰 2층 + 충분한 에폭에서 시험 정확도 90% 안팎. 학습 ≫ 시험 차이가 벌어지는 마지막 행이 **과적합 시작점**. 학생이 직접 그 차이를 발견하도록 유도.

3–2 증강의 효과 — 모범 답안

예시 증강 전: 학생이 그린 글씨가 평소 MNIST 데이터보다 살짝 기울거나 두꺼워서 모델이 헛다리. 증강 후(같은 그림을 회전·이동·축소 N번): 모델이 "이 그림은 위치·각도가 변해도 같은 숫자다"라는 불변성을 배워 적중.

자주 틀림 "증강 = 데이터를 늘린 것 자체가 좋다"로 단순화하는 답. **"같은 라벨의 다양한 변형을 보게 한다"**는 점이 핵심임을 짚어줄 것.

3–3 모델이 끝까지 헷갈리는 페어 — 예시

예시 4-9, 3-8, 5-6 등이 자주 등장. 사람이 보면 닫힘/열림 곡선이 한두 픽셀 차이지만, 신경망에는 매우 비슷하게 매핑됨. **특징을 더 잘 잡는 구조(CNN)가 필요하다는 동기부여**가 됨 — 이번 과정 범위 밖이지만 관심 학생에게 한 마디 짚어줄 만함.

STEP 4. 마무리 — 정답

정리 핵심 빈칸 — 정답

문제가 어려워질수록 신경망은 더 (**커**)져야 한다.
그러나 무한정 키우면 (**과적합**) 위험이 생기고, 이를 줄이는 한 가지 방법이 (**데이터 증강** / 또는 **데이터 추가**)이다.
은닉층은 입력의 (**부분 패턴(특징)**)을 잡아내고, 출력층은 그것을 (**조합**)해 분류한다.

관찰·수행 평가 루브릭

수준	도트 학습 (Phase 10)	비교 실험 (Phase 11)	MNIST·증강 (Phase 12)
A 도달	두 라벨 데이터를 5장 이상 모아 95% 이상 도달. 가중치 시각화의 의미를 자기 말로 설명.	A·B·C 모두 학습 후 클래스 수와 정확도의 관계를 그래프적 직관으로 설명. 1·7 혼동 원인을 픽셀 패턴으로 설명.	은닉/에폭 변화에 따른 학습 vs 시험 차이를 관찰해 과적합 신호를 식별. 증강의 효과를 "불변성 학습"으로 설명.
B 진행	적당히 학습은 됐지만 가중치 시각화 의미를 직관 수준으로만 설명.	두 단계만 비교, 클래스 수의 영향을 부분적으로만 설명.	모델 변경의 영향을 표로 기록하지만 일반화 차이를 못 짚음.
C 보충	데이터 부족으로 학습 안 됨. 가중치 시각화 보고 답을 적지 못함.	한 단계만 풀고 비교 못함.	설정을 바꿨지만 변화 의미를 해석하지 못함.

전이 포인트 4부까지는 모두 **분류** 문제였다. 5부에서는 같은 도구로 **새로운 것을 만드는**(생성) 모델로 넘어간다. "분류기를 뒤집으면 생성기가 된다"는 직관을 미리 던져둘 것.