3·4부 — 직접 만들기와 깊은 학습

앱 페이즈 10~12 · 학생용과 동일 구조 + 정답·해설

> **핵심 메시지** "복잡한 문제는 더 큰 신경망을 요구한다, 그러나 크기만 키우면 과적합이 늘어난다." 3·4부에서는 모델 크기·데이터 양·증강 세 축으로 일반화 감각을 길러내는 게 목표.

STEP 1. 도트 그림 학습 — 가중치 시각화의 의미

활동지 운영 학생용은 두 라벨 평균 패턴(가로줄 A·세로줄 B)을 미리 그려 제공한다. 학생들이 직접 도트 캔버스에 그리지 않고, 두 평균을 머릿속으로 빼서 가중치 시각화 결과를 칸별로 채우는 활동.

1-1 두 라벨 패턴 — 운영

수업 팁 "위쪽 가로줄(A) vs 왼쪽 세로줄(B)"은 **대조가 강하고 겹치는 영역이 작은** 의도적 단순 사례. 시간 여유가 있으면 다른 페어("원 vs X" 등)를 추가로 제시해 같은 분석을 반복.

1-2 가중치 시각화 — 정답

정답 — 8×8 칸별 분류 위쪽 두 줄(0·1행) 중 왼쪽 두 칸(0·1열) 4개 = **둘 다 켜짐 → 0(점)**
위쪽 두 줄의 나머지 12칸(0·1행 × 2~7열) = **A에만 켜짐 → 양수(흰색)**
왼쪽 두 열의 나머지 12칸(2~7행 × 0·1열) = **B에만 켜짐 → 음수(검정)**
그 외 36칸 = 둘 다 안 켜짐 → 0(빈칸)

한 줄 의미 "가중치 시각화 = **두 라벨의 평균 픽셀 차이**가 된다."

자주 틀림 겹치는 4칸을 양수로 채우는 경우. **"둘 다 켜진 자리는 분류에 도움 안 됨 → 0"**임을 짚을 것.

1-3 새 그림 분류 — 정답

정답 "위쪽 두 줄만 켜진 그림": A 양수 영역에 픽셀이 모임 → 점수 부호 = **+** → 예측 = **A**.
"왼쪽 두 줄만 켜진 그림": B 음수 영역에 픽셀이 모임 → 점수 부호 = **−** → 예측 = **B**.

한 줄 정의 "단일 뉴런이 두 그림을 구분한다 = **두 라벨의 평균 차이 패턴과 입력의 내적을 보고, 양수면 A·음수면 B로 결정하는 일**." 학생 답이 "비슷한 무늬가 그림을 구분한다"는 직관 수준이어도 인정.

1-4 학습 데이터 양과 일반화 — 정답

정답 테스트 정확도는 **올라간다** (60→80→92%).
학습 정확도와 테스트 정확도의 차이는 **줄어든다** (40%p → 20%p → 4%p).
이 현상의 이름: **과적합(overfitting)** 해소 / 또는 **일반화 향상**. (2부 STEP 2에서 본 개념의 반복.)

수업 팁 "학습 정확도가 100% → 96%로 떨어진 게 좋은 신호"라는 점을 다시 한 번 짚어주면, 2부에서 본 일반화 개념이 픽셀 분류에서도 그대로 적용됨이 명확해짐.

STEP 2. 신경망 설계 — 단계 A·B·C 비교 (Phase 11)

앱 운영 Phase 11은 **난이도 단계 3개(🟢 A=2종 / 🟡 B=3종 / 🔴 C=10종)**를 차례로 학습시키며 비교표를 채우는 구조. 단계마다 **추천 은닉 크기가 다름**(A=4, B=8, C=16). 활동지 표는 셋 다 **은닉 8로 통일**해 클래스 수 변화의 영향만 따로 보게 만든 의도적 단순화. 학생이 앱에서 추천값으로 다시 학습시키면 정확도가 더 오르는 모습(특히 C)을 추가로 관찰하게 안내할 것. 학습 식 (페이즈 5의 갱신식 `w ← w - η · dw`)이 다층에서도 그대로 적용된다는 점이 페이지 상단 박스에 명시돼 있음.

2-1 단계 A·B·C — 정답

정답 클래스 수가 늘어날수록 정확도는 **내려간다**.
파라미터 수가 비슷한데 정확도 차이가 큰 이유: 클래스 수가 많을수록 모델이 **어려워진다**(같은 표현력으로 더 많은 결정 경계를 만들어야 함).
단계 C 검산: (784+1)·8 + (8+1)·10 = **6280** + **90** = **6,370**.

수업 팁 "같은 신경망에 더 어려운 문제를 던지면 정확도가 떨어진다"는 직관이 핵심. 다음 2-2에서 "그럼 신경망을 키우면?"으로 자연스럽게 이어진다. 도전 활동: 앱에서 단계 C에 은닉 16(추천값)·24·32로 학습시켜 정확도 향상을 직접 관찰.

2-2 은닉 크기 — 정답

정답 은닉을 키우면 정확도는 **올라간다**(70→82→88→91%).
하지만 두 배씩 키워도 증가 폭(12 → 6 → 3)은 **점점 작아진다**(수확체감).
이유 작은 모델이 못 잡던 패턴을 큰 모델이 잡으면서 정확도가 빠르게 오르지만, 이미 잡힌 패턴 위에 더 큰 모델을 얹어도 새로 잡을 패턴이 적기 때문. 또한 **과적합**이 시작되어 학습 정확도만 오르고 시험 정확도는 멈출 수 있음.

자주 틀림 "키우면 무조건 좋다"는 답. **"증가 폭이 줄어든다"**는 점과 **과적합 위험**을 함께 짚을 것.

2-3 1·7 혼동 — 모범 답안

예시 1과 7은 모두 **세로 직선이 핵심 특징**이다. 7은 위쪽에 짧은 가로획이 추가될 뿐이라, 가로획이 흐릿하거나 작은 글씨에서 신경망이 두 클래스의 신호를 분리하기 어렵다.

STEP 3. MNIST 도전

앱 운영 Phase 12에는 **5단계 프리셋**(🐣 시작·🌱 작게·🌳 보통·🚀 크게·👑 최강) 버튼이 있다. 학생이 한 번 클릭하면 **은닉층 구성 + 에폭이 동시에** 셋업되는 구조. 활동지 표는 위쪽 4단계에 매칭. 👑 **최강(128·64 2층·30에폭)**은 도전 과제로 남겨두고, 학생들이 시험 정확도가 더 오르는지 / 아니면 학습-시험 격차만 더 벌어지는지(과적합) 직접 비교하게 운영. 에폭 슬라이더는 1~40까지 자유롭게 조정 가능하니 프리셋 외 임의 설정도 가능.

3-1 구조·설정 변화 — 정답

정답 🐣 → 🌱 은닉 4 → 8로 키우면 시험 정확도 **오른다**(65 → 78%).
🌱 → 🌳 은닉 8 → 32, 에폭 8 → 15로 키우면 **오른다**(78 → 88%).
🌳 → 🚀 1층 [32]에서 2층 [64, 32]로 깊게 쌓으면 **오른다**(88 → 92%).
🚀 에서 학습 97%·시험 92%로 격차가 커지는 현상: **과적합(overfitting)**.

수업 팁 🐣 → 🌱 · 🌳 단계는 "표현력 부족" 해소, 🚀 → 👑 단계는 "표현력 과잉" 시작. 👑 최강을 직접 돌려본 학생이 시험 정확도가 92~93%에서 멈추거나 오히려 떨어지는 모습을 발견하면 매우 좋은 신호. **"무한정 키우면 학습 정확도만 99%로 가고 시험 정확도는 천장에 부딪힌다"**를 자기 말로 정리시킬 것.

3-2 증강의 효과 — 모범 답안

예시 증강 전: 학생이 그린 7이 살짝 기울어져 모델이 1로 오인. 증강 후(같은 7을 회전·이동·축소 15번): 모델이 "이 그림은 **각도·위치·크기가 변해도 같은 7이다**"라는 **불변성**을 학습 → 적중.

자주 틀림 "증강 = 데이터를 늘린 것 자체가 좋다"는 답. **"같은 라벨의 다양한 변형을 보게 해 모델이 본질적인 패턴(7의 모양)에 집중하도록 한다"**는 점이 핵심.

3-3 한계 페어 — 모범 답안

예시 **4-9**: 둘 다 위쪽에 닫힌 곡선·아래쪽에 세로 직선. 차이는 4의 위쪽 곡선이 한 점에서 살짝 열려 있다는 정도. 글씨 두께·기울기에 따라 그 한 점이 흐려지면 구별 불가.
3-8: 두 곡선이 닫힘 vs 열림. 8의 두 원이 모두 닫혀 있고 3은 오른쪽만 곡선. 픽셀 단위로는 한두 칸 차이.
5-6: 위쪽 가로획·중간 곡선이 거의 같고, 차이는 5의 위쪽이 직각인지 둥근지.

전이 이런 픽셀 단위 미세 차이는 단순 MLP가 잘 못 잡고, **지역 특징을 잡는 구조(CNN)**가 필요하다는 동기부여로 연결. 관심 있는 학생에게 한 마디 짚어줄 만함.

STEP 4. 마무리 — 정답

정리 **핵심 빈칸 — 정답**

문제가 어려워질수록 신경망은 더 (**커**)져야 한다.
그러나 무한정 키우면 (**과적합**) 위험이 생기고, 이를 줄이는 한 가지 방법이 (**데이터 증강** / 또는 **데이터 추가**)이다.
은닉층은 입력의 (**부분 패턴(특징)**)을 잡아내고, 출력층은 그것을 (**조합**)해 분류한다.

관찰·수행 평가 루브릭

수준	도트 학습 (Phase 10)	비교 실험 (Phase 11)	MNIST·증강 (Phase 12)
A 도달	두 라벨 데이터를 5장 이상 모아 95% 이상 도달. 가중치 시각화의 의미를 자기 말로 설명.	A·B·C 모두 학습 후 클래스 수와 정확도의 관계를 그래프적 직관으로 설명. 1·7 혼동 원인을 픽셀 패턴으로 설명.	은닉/에폭 변화에 따른 학습 vs 시험 차이를 관찰해 과적합 신호를 식별. 증강의 효과를 "불변성 학습"으로 설명.
B 진행	적당히 학습은 됐지만 가중치 시각화 의미를 직관 수준으로만 설명.	두 단계만 비교, 클래스 수의 영향을 부분적으로만 설명.	모델 변경의 영향을 표로 기록하지만 일반화 차이를 못 짚음.
C 보충	데이터 부족으로 학습 안 됨. 가중치 시각화 보고 답을 적지 못함.	한 단계만 풀고 비교 못함.	설정을 바꿨지만 변화 의미를 해석하지 못함.

전이 포인트 4부까지는 모두 **분류** 문제였다. 5부에서는 같은 도구로 **새로운 것을 만드는**(생성) 모델로 넘어간다. "분류기를 뒤집으면 생성기가 된다"는 직관을 미리 던져둘 것.