6부 후반 — 시퀀스에서 GPT까지

시퀀스 · 어텐션 · 멀티헤드 트랜스포머 · GPT 샘플링

앱 페이즈 19~22 (히든 스테이지) · 대상: 고등학생 · 활동 시간 약 90분

> **학습 목표** ① 단어 순서가 의미를 만든다는 점을 평균 임베딩의 한계로 설명한다. ② 어텐션의 기본 식(점수 → 가중치 → 가중합)을 직접 손으로 계산한다. ③ 멀티헤드와 깊이가 표현력을 어떻게 늘리는지 설명한다. ④ 샘플링 온도(temperature)와 top-k가 생성 결과에 미치는 영향을 관찰한다.

학년 반 번호 _____ 이름 _____

STEP 1. 시퀀스 — 순서가 의미를 만드는 순간

> **이 절의 목표**
> 단어 순서가 의미를 어떻게 만드는지를 직접 손계산으로 확인하고, 평균만 쓰는 단순 모델의 한계와 RNN의 발상을 이해한다.

> **평균(BoW)의 한계와 RNN의 발상**
> ▸ **평균 임베딩**: 문장의 모든 단어 벡터를 평균. → 단어 순서가 사라짐.
> ▸ **RNN**: 단어를 한 개씩 순서대로 받으며 **이전 상태**를 다음으로 전달. 순서가 보존됨.

1-1 순서가 바뀌면 의미가 뒤집힌다

문장 A	문장 B	의미가 같은가?
고양이가 쥐를 잡았다	쥐가 고양이를 잡았다	
철수는 영희에게 책을 줬다	영희는 철수에게 책을 줬다	
Dog bites man	Man bites dog	

1-2 평균 임베딩의 한계 — 직접 계산

단어 임베딩이 다음과 같다고 하자.

```
I = (0.9, 0.2)  /  you = (-0.9, 0.2)  /  love = (0.0, 0.9)
```

"I love you"와 "You love I"의 단어 임베딩 평균을 각각 계산.

```
avg("I love you") = ( ___________, ___________ )
avg("You love I") = ( ___________, ___________ )
두 평균은 같다 / 다르다. ☞ 동그라미: ___________
```

의미가 정반대인 두 문장이 평균 임베딩에서는 같은 점이 됩니다. 이 사실로부터 어떤 결론을 내릴 수 있나요?

1–3 **RNN의 직관 — 상태 갱신 표**

RNN은 단어를 한 개씩 받으며 hidden state h를 갱신합니다. 단순화 규칙: 새 `h = 0.5·이전 h + 0.5·현재 단어`. (가중치는 학습되는 값이지만 여기서는 단순 평균.)

"I love you" (I=0.9, love=0.0, you=−0.9)와 "You love I" (you=−0.9, love=0.0, I=0.9)의 마지막 상태를 직접 계산하세요. 시작 $h_0 = 0$.

	"I love you"	"You love I"
h_0	0	0
$h_1 = 0.5 \cdot h_0 + 0.5 \cdot$ 첫 단어		
$h_2 = 0.5 \cdot h_1 + 0.5 \cdot$ 둘째 단어		
$h_3 = 0.5 \cdot h_2 + 0.5 \cdot$ 셋째 단어 (마지막 상태)		

두 마지막 상태는 (같다 / 다르다). ☞ _____ 평균 임베딩과 달리 RNN은 순서 정보를 (잃는다 / 보존한다). ☞ _____

STEP 2. 어텐션 — 어디에 집중할지

이 절의 목표

단어들끼리 서로 점수를 매기는 어텐션의 핵심 절차(점수 → 가중치 → 가중합)를 직접 손계산으로 따라가며, 트랜스포머의 심장이 어떤 일을 하는지 이해한다.

어텐션 한 줄 식

점수 $S = Q \cdot K^T$ → 가중치 $A = \text{softmax}(S)$ → 출력 $O = A \cdot V$

- Q(질문)·K(키)로 누구에게 집중할지 정하고, V(값)에서 그 비율로 가져옴.
- 이 페이지에서는 단순화: **Q = K = V = 단어 임베딩**.

2–1 **"고양이는 쥐를 봤다" — 어텐션 가중치 직접 계산**

단어 임베딩이 다음과 같다.

```
고양이는 = (0.9, 0.7, 0.2, 0.1)
쥐를 = (0.2, 0.6, 0.8, 0.1)
봤다 = (0.1, 0.2, 0.3, 0.9)
```

"봤다"가 다른 단어들에게 매긴 점수(내적)를 계산해보세요.

```
S("봤다", "고양이는") = 0.1·0.9 + 0.2·0.7 + 0.3·0.2 + 0.9·0.1 = _____
S("봤다", "쥐를") = 0.1·0.2 + 0.2·0.6 + 0.3·0.8 + 0.9·0.1 = _____
S("봤다", "봤다") = 0.1² + 0.2² + 0.3² + 0.9² = _____
```

정규화 결과(소수점 둘째 자리 반올림)는 다음과 같다고 가정합시다 (앱이 보여주는 값을 적어 넣어도 됨).

```
A = softmax(S) ≈ ( 고양이는 = 0.30 ,   쥐를 = 0.30 ,   봤다 = 0.40  )
```

2–2 **가중합 — "봤다"의 새 표현 계산**

위 가중치를 사용해 "봤다"의 새 출력 벡터를 계산하세요.

```
O = 0.30·(0.9, 0.7, 0.2, 0.1) + 0.30·(0.2, 0.6, 0.8, 0.1) + 0.40·(0.1, 0.2, 0.3, 0.9)
= ( ___________, ___________, ___________, ___________ )
```

"봤다"의 원래 벡터와 비교했을 때, 어느 방향으로 가까워졌나요? (어떤 단어의 영향이 가장 컸나요)

2–3 **어텐션 행렬 시각화**

아래는 앱이 보여주는 3×3 어텐션 행렬의 한 예시입니다. 색이 진할수록 가중치가 큼.

Q ↓ \ K →	고양이는	쥐를	봤다
고양이는	0.7	0.2	0.1
쥐를	0.2	0.6	0.2
봤다	0.4	0.4	0.2

"봤다" 행이 다른 두 단어를 비슷하게 보고 있다(0.4·0.4·0.2). 이것이 의미하는 바는?

STEP 3. 멀티헤드와 트랜스포머 블록

이 절의 목표

한 어텐션이 한 관계만 본다는 한계를 **여러 헤드**로 극복하는 방법을 직접 행렬에서 찾고, 어텐션 + FFN을 한 블록으로 묶은 트랜스포머의 구성 요소를 식별한다.

멀티헤드 = 동시에 여러 관계를 보기 한 어텐션은 한 가지 관계만 본다. 트랜스포머는 여러 헤드를 두고 각자 다른 관점(주격·대상·목적어 등)을 동시에 학습. 결과를 이어 붙여 다음 층으로.

3–1 **"철수가 영희에게 책을 줬다" — 4개 헤드 행렬**

아래 4개 헤드의 어텐션 행렬은 모두 "줬다" 행만 표시한 것. 각 헤드에서 가장 큰 가중치가 어느 단어로 향하는지 동그라미하세요. (단어: 철수가, 영희에게, 책을, 줬다)

헤드	철수가	영희에게	책을	줬다(자기)
① 주격 헤드	0.6	0.1	0.1	0.2
② 대상 헤드	0.1	0.6	0.1	0.2
③ 목적어 헤드	0.1	0.1	0.7	0.1
④ 전체 문장 헤드	0.25	0.25	0.25	0.25

표를 보고 빈칸을 채우세요.

헤드	가장 주목하는 단어	그 헤드가 잡는 의미 관계
① 주격 헤드		누가 ___ ?
② 대상 헤드		누구에게 ___ ?
③ 목적어 헤드		무엇을 ___ ?
④ 전체 문장 헤드		전체 문맥 (특정 단어에 쏠리지 않음)

한 어텐션 헤드만 있다면 ①~③ 중 하나의 관계만 잡힌다. 멀티헤드가 필요한 이유를 한 줄로:

3–2 **트랜스포머 블록 — 구성 요소 빈칸**

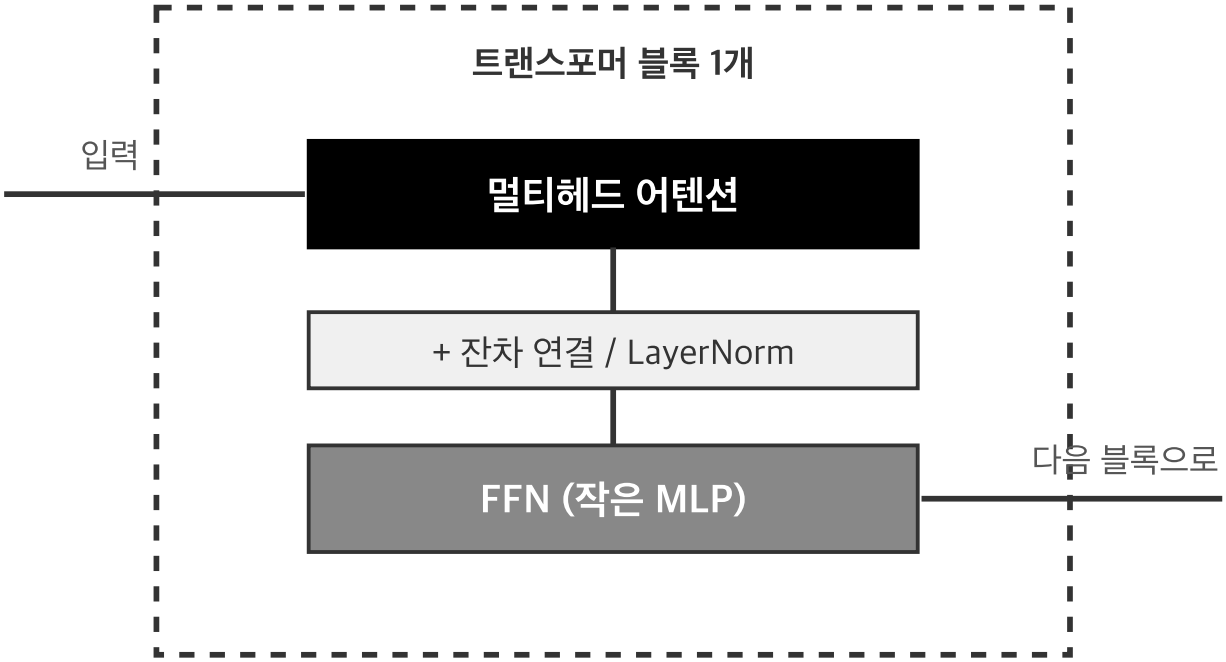

▲ 트랜스포머 블록 1개의 구성

블록의 4가지 부품 이름을 적어보세요.

1. ① _____ — 단어들끼리 서로 점수 매기고 가중합
2. ② _____ — 입력을 출력에 더해 학습 안정화
3. ③ _____ — 각 단어에 작은 MLP 적용
4. ④ _____ — 출력을 정규화해 다음 층 입력으로

3–3 **1층 vs 6층 — 깊이의 의미 (결과 표)**

깊이	잡아내는 패턴
1층	바로 옆 단어와의 관계만 (주어-동사 등)
3층	두 단계 떨어진 관계도 잡힘. 문장의 일부 의미 구조
6층	문장 전체의 의미·역할 구조가 한 표현으로 통합

표를 보고 한 줄로 정리:

깊이가 늘어날수록 모델은 _____ 단어 관계와 더 _____한 패턴을 잡는다.

> 실제 GPT-3는 96층, GPT-4는 그보다 더 깊다. 깊이가 늘어나면 **긴 문맥과 추상 패턴**을 다룰 수 있게 된다.

STEP 4. GPT의 다음 토큰 — 샘플링이 곧 창의성

> **이 절의 목표**
> GPT가 매 단계 어휘 전체에 대한 확률 분포를 만들고 그 안에서 다음 토큰을 뽑는 절차를, 분포 표·온도 비교 표로 직접 해석한다.

> **한 토큰씩 — 자기회귀 생성** 매 단계: 어휘 전체에 대한 **점수(logit)** → softmax → 확률 분포 → **샘플링** → 다음 토큰. 그 토큰을 입력 끝에 붙이고 다시 반복.
> ▸ **temperature(온도)**: softmax 전에 logit을 T로 나눔. 낮으면 보수적·반복, 높으면 다양·산만.
> ▸ **top-k**: 상위 k개 토큰만 후보로 두고 그 안에서 샘플링.

4–1 **"고양이는" 다음 — 분포 표**

"고양이는" 뒤에 올 다음 토큰의 상위 5개 후보와 확률 (T = 1.0):

순위	1	2	3	4	5	합
토큰	귀엽다	잔다	쥐를	동물	집사	—
확률	0.27	0.16	0.05	0.04	0.03	

상위 5개 확률의 합 = _____. 나머지(다른 토큰들의 확률 합) = 1 – 합 = _____. 즉 어휘는 5개보다 훨씬 많고, 확률은 모든 토큰에 분산되어 있다.

4–2 **온도(temperature) 변화 — 결과 표**

같은 logit 분포에 온도 T만 바꿔 softmax를 적용한 결과:

T	1순위 확률	분포 모양	한 줄 묘사
0.2 (낮음)	0.85	매우 뾰족 (1순위에 거의 몰림)	반복·뻔함
1.0 (기본)	0.27	중간 (위 4-1 분포)	자연스러움
2.0 (높음)	0.08	평탄 (거의 균등)	엉뚱·환각

표를 보고 빈칸을 채우세요.

```
T가 작을수록 (보수적 / 다양). ☞ _____
T가 클수록 (예측 가능 / 의외성↑). ☞ _____
"GPT가 너무 똑같은 답만 한다" 싶으면 T를 (낮춰야 / 높여야) 한다. ☞ _____
```

4-3 자기회귀 생성 — 결과 표

같은 시작 "고양이는"으로 5번 연속 생성한 결과 (T = 1.0):

시도	생성된 문장
1	고양이는 귀엽다.
2	고양이는 잔다.
3	고양이는 쥐를 잡는다.
4	고양이는 귀엽다.
5	고양이는 동물이다.

5번 모두 "고양이는"으로 시작했지만 결과가 다른 이유를 한 줄로:

시도 1과 4에서 같은 결과가 나온 이유는?

4-4 "창의성"의 정체

"GPT의 창의성"이라는 표현이 사실은 무엇을 가리키는지, 분포·샘플링·온도 개념을 사용해 30~50자로 정리.

STEP 5. 6부 후반 마무리

정리 **흐름 빈칸**

토큰 → (_____) 벡터 → (_____) 어텐션 + FFN을 가진 트랜스포머 블록을 N층 통과
→ 마지막에 어휘에 대한 (_____)이 만들어지고, (_____)로 다음 토큰을 뽑는다.
이 과정을 반복(자기회귀)해 문장 전체가 만들어진다.

서술 **친구에게 설명하기**

"GPT가 한 문장을 만드는 동안 내부에서 무슨 일이 일어나는가?"를 임베딩·어텐션·블록·샘플링 네 단어를 모두 사용해 6~8문장으로 설명하세요.